

PROBABILITĂȚI

Sem. 1, Funcțiile lui Euler

Funcția Gamma a lui Euler $\Gamma : (0, \infty) \rightarrow (0, \infty)$ $\Gamma(a) = \int_0^{\infty} x^{a-1} e^{-x} dx$

1. $\Gamma(1) = 1$; 2. $\Gamma(a+1) = a\Gamma(a)$, $\forall a > 0$;

3. $\Gamma(n+1) = n!$, $\forall n \in \mathbb{N}$; 4. $\Gamma\left(\frac{1}{2}\right) = \sqrt{2} \int_0^{\infty} e^{-\frac{t^2}{2}} dt = \int_{\mathbb{R}} e^{-t^2} dt = \sqrt{\pi}$.

Funcția Beta a lui Euler $\beta : (0, \infty) \times (0, \infty) \rightarrow (0, \infty)$ $\beta(a, b) = \int_0^1 x^{a-1} (1-x)^{b-1} dx$

1. $\beta(a, 1) = \frac{1}{a}$, $\forall a > 0$; 2. $\beta(a, b) = \beta(b, a)$, $\forall a, b > 0$; 3. $\beta(a, b) = \frac{a-1}{b} \beta(a-1, b+1)$, $\forall a > 1, b > 0$;

4. $\beta(a, b) = \frac{b-1}{a+b-1} \beta(a, b-1) = \frac{a-1}{a+b-1} \beta(a-1, b)$, $\forall a, b > 1$; 5. $\beta(a, b) = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$, $\forall a, b > 0$.

Sem. 2, Prob. clasică, geometrică, condiționată; Evenimente independente; Formula lui Bayes

Probabilitate clasică: $P(A) = \frac{\text{nr. of favorable outcomes}}{\text{total nr. of possible outcomes}}$.

Probabilitate condiționată: $P(A|B) = \frac{P(A \cap B)}{P(B)}$, $P(B) \neq 0$.

Evenimente independente: A, B independente $\Leftrightarrow P(A \cap B) = P(A)P(B) \Leftrightarrow P(A|B) = P(A)$

Formula probabilității totale: $\{A_i\}_{i \in I}$ o partiție a lui S , atunci $P(A) = \sum_{i \in I} P(A_i)P(A_i|A)$

Probabilitatea intersecției: $P\left(\bigcap_{i=1}^n A_i\right) = P(A_1)P(A_2|A_1)P(A_3|A_1 \cap A_2) \dots P\left(A_n \mid \bigcap_{i=1}^{n-1} A_i\right)$

Formula lui Bayes: $\{A_i\}_{i \in I}$ o partiție a lui S , atunci $P(A_j|A) = \frac{P(A|A_j)P(A_j)}{\sum_{i \in I} P(A|A_i)P(A_i)}$, $\forall j \in I$

Sem. 3, Scheme probabilistice

Schema binomială: Probabilitatea ca din n repetări independente ale unui experiment, un eveniment care apare cu aceeași probabilitate p , la fiecare repetare, să se realizeze de k ori, este $P(n, k) = C_n^k p^k q^{n-k}$, $k = \overline{0, n}$.

Schema multinomială: Probabilitatea ca din $n = n_1 + n_2 + \dots + n_r$ repetări ale experimentului, evenimentul E_i să se realizeze de n_i ori, unde $p_i = P(E_i)$, $i = \overline{1, r}$, is $P(n; n_1, \dots, n_r) = \frac{n!}{n_1! n_2! \dots n_r!} p_1^{n_1} p_2^{n_2} \dots p_r^{n_r}$.

Schema lui Bernoulli fără revenire (hipergeometrică): Probabilitatea ca din n bile extrase din totalul de N bile albe și negre existente în urnă (din care n_1 albe), k să fie albe și $n-k$ negre, ($0 \leq k \leq n_1$, $0 \leq n-k \leq N-n_1$), este $P(n; k) = \frac{C_{n_1}^k C_{N-n_1}^{n-k}}{C_N^n}$.

Schema lui Bernoulli fără revenire cu r stări: Probabilitatea ca din $M = m_1 + m_2 + \dots + m_r$ extrageri, să avem m_i bile de culoarea i din totalul de n_i , $i = \overline{1, r}$, ($n = n_1 + n_2 + \dots + n_r$), este $P(n; m_1, \dots, m_r) = \frac{C_{n_1}^{m_1} C_{n_2}^{m_2} \dots C_{n_r}^{m_r}}{C_n^M}$.

Schema lui Poisson: Probabilitatea de a avea k succese din n încercări, cu probabilitate de succes p_i la a i -a încercare ($q_i = 1 - p_i$), $i = \overline{1, n}$ este $P(n; k) = \sum_{1 \leq i_1 < \dots < i_k \leq n} p_{i_1} \dots p_{i_k} q_{i_{k+1}} \dots q_{i_n}$, $i_{k+1}, \dots, i_n \in \{1, \dots, n\} \setminus \{i_1, \dots, i_k\}$ = coeficientul lui x^k în dezvoltarea $(p_1 x + q_1)(p_2 x + q_2) \dots (p_n x + q_n)$.

Schema lui Pascal: Probabilitatea ca al n -lea succes să apară după k insuccese, probabilitatea de succes fiind p ($q = 1 - p$), este $P(n; k) = C_{n+k-1}^{n-1} p^n q^k = C_{n+k-1}^k p^n q^k$.

Schema geometrică: Probabilitatea ca primul succes să apară după k insuccese, probabilitatea de succes fiind p ($q = 1 - p$), este $p_k = p q^k$.

Sem. 4, Variabile aleatoare și vectori aleatori de tip discret

Distribuția Bernoulli de parametru $p \in (0, 1)$: $X \begin{pmatrix} 0 & 1 \\ 1-p & p \end{pmatrix}$

Distribuția binomială de parametri $n \in \mathbb{N}, p \in (0, 1)$: $X \begin{pmatrix} k \\ C_n^k p^k q^{n-k} \end{pmatrix}_{k=0, \overline{n}}$

Distribuția hipergeometrică de parametri $a, b, n \in \mathbb{N}, n \leq a$: $X \begin{pmatrix} k \\ p_k \end{pmatrix}_{k=0, \overline{n}}, p_k = \frac{C_a^k C_b^{n-k}}{C_{a+b}^n}$

Distribuția Poisson de parametru $\lambda > 0$: $X \begin{pmatrix} k \\ p_k \end{pmatrix}_{k \in \mathbb{N}}, \text{ where } p_k = \frac{\lambda^k}{k!} e^{-\lambda}$

Distribuția Pascal de parametri $n \in \mathbb{N}, p \in (0, 1)$: $X \begin{pmatrix} k \\ C_{n+k-1}^k p^n q^k \end{pmatrix}_{k \in \mathbb{N}}$

Distribuția geometrică de parametru $p \in (0, 1)$: $X \begin{pmatrix} k \\ pq^k \end{pmatrix}_{k \in \mathbb{N}}$

Distribuția uniformă de tip discret de parametru $m \in \mathbb{N}$: $X \begin{pmatrix} k \\ \frac{1}{m} \end{pmatrix}_{k=1, \overline{m}}$

Funcție de repartiție $F_X : \mathbb{R} \rightarrow \mathbb{R}, F_X(x) = P(X < x)$

Vector aleator de tip discret: $(X, Y) : S \rightarrow \mathbb{R}^2$,

pdf $p_{ij} = P(X = x_i, Y = y_j), (i, j) \in I \times J$,

cdf $F = F_{(X,Y)} : \mathbb{R}^2 \rightarrow \mathbb{R}, F(x, y) = P(X < x, Y < y) = \sum_{x_i < x} \sum_{y_j < y} p_{ij}, \forall (x, y) \in \mathbb{R}^2$,

$p_i = P(X = x_i) = \sum_{j \in J} p_{ij}, \forall i \in I, q_j = P(Y = y_j) = \sum_{i \in I} p_{ij}, \forall j \in J$ (densități marginale)

Operații: $X \begin{pmatrix} x_i \\ p_i \end{pmatrix}_{i \in I}, Y \begin{pmatrix} y_j \\ q_j \end{pmatrix}_{j \in J}$

X și Y sunt **independente** $\Leftrightarrow p_{ij} = P(X = x_i, Y = y_j) = P(X = x_i) P(Y = y_j) = p_i q_j$.

$X + Y \begin{pmatrix} x_i + y_j \\ p_{ij} \end{pmatrix}_{(i,j) \in I \times J}, \alpha X \begin{pmatrix} \alpha x_i \\ p_i \end{pmatrix}_{i \in I}, XY \begin{pmatrix} x_i y_j \\ p_{ij} \end{pmatrix}_{(i,j) \in I \times J}, X/Y \begin{pmatrix} x_i / y_j \\ p_{ij} \end{pmatrix}_{(i,j) \in I \times J} (y_j \neq 0)$

Sem. 5, Var. aleatoare și vectori aleatori de tip continuu; Operații cu var. al. de tip cont.

$X : S \rightarrow \mathbb{R}$ variabilă aleatoare de tip continuu cu pdf $f : \mathbb{R} \rightarrow \mathbb{R}, \text{ cdf } F : \mathbb{R} \rightarrow \mathbb{R}$. Proprietăți:

1. F este absolut continuă și $F(x) = P(X < x) = \int_{-\infty}^x f(t) dt$ 2. $f(x) \geq 0, \forall x \in \mathbb{R}, \int_{\mathbb{R}} f(x) = 1$

3. $P(X = x) = 0, \forall x \in \mathbb{R}, P(a < X < b) = \int_a^b f(t) dt$ 4. F este continuă la stânga și crescătoare

5. $F(-\infty) = 0, F(\infty) = 1$

Vector aleator de tip cont.: $(X, Y) : S \rightarrow \mathbb{R}^2$, pdf $f = f_{(X,Y)} : \mathbb{R}^2 \rightarrow \mathbb{R}, \text{ cdf } F = F_{(X,Y)} :$

$\mathbb{R}^2 \rightarrow \mathbb{R}, F(x, y) = P(X < x, Y < y) = \int_{-\infty}^x \int_{-\infty}^y f(u, v) dv du, \forall (x, y) \in \mathbb{R}^2$. Proprietăți:

1. $P(a_1 \leq X < b_1, a_2 \leq Y < b_2) = F(b_1, b_2) - F(a_1, b_2) - F(b_1, a_2) + F(a_1, a_2)$

2. F este continuă la stânga și crescătoare în raport cu fiecare variabilă

3. $F(\infty, \infty) = 1, F(-\infty, y) = F(x, -\infty) = 0, \forall x, y \in \mathbb{R}$

4. X, Y independente $\Leftrightarrow F(x, y) = F_X(x) F_Y(y), \Leftrightarrow f_{(X,Y)}(x, y) = f_X(x) f_Y(y), \forall (x, y) \in \mathbb{R}^2$

5. $F_X(x) = F(x, \infty), F_Y(y) = F(\infty, y), \forall x, y \in \mathbb{R}$ 6. $P((X, Y) \in D) = \int_D \int f(x, y) dy dx$

7. $f_X(x) = \int_{\mathbb{R}} f(x, y) dy, \forall x \in \mathbb{R}, f_Y(y) = \int_{\mathbb{R}} f(x, y) dx, \forall y \in \mathbb{R}$ (densități marginale)

8. Operații:

Suma: $f_{X+Y}(z) = \int_{\mathbb{R}} f_{(X,Y)}(u, z-u) du \stackrel{X,Y \text{ ind}}{=} \int_{\mathbb{R}} f_X(u) f_Y(z-u) du$

Produsul: $f_{XY}(z) = \int_{\mathbb{R}} f_{(X,Y)}\left(u, \frac{z}{u}\right) \frac{1}{|u|} du \stackrel{X,Y \text{ ind}}{=} \int_{\mathbb{R}} f_X(u) f_Y\left(\frac{z}{u}\right) \frac{1}{|u|} du$

Câtul: $f_{X/Y}(z) = \int_{\mathbb{R}} f_{(X,Y)}(uz, u) |u| du \stackrel{X,Y \text{ ind}}{=} \int_{\mathbb{R}} f_X(uz) f_Y(u) |u| du$

Funcția $Y = g(X)$: $g : \mathbb{R} \rightarrow \mathbb{R}$ derivabilă cu $g' \neq 0$, strict monotonă, $f_Y(y) = \frac{f_X(g^{-1}(y))}{|g'(g^{-1}(y))|}$, $y \in g(\mathbb{R})$

Sem. 6, Caracteristici numerice ale variabilelor aleatoare

Valoarea medie:

X discr. cu pdf $X \left(\begin{smallmatrix} x_i \\ p_i \end{smallmatrix} \right)_{i \in I}$, $M(X) = \sum_{i \in I} x_i p_i$, X cont. cu pdf $f : \mathbb{R} \rightarrow \mathbb{R}$, $M(X) = \int_{\mathbb{R}} x f(x) dx$.

Dispersia: $D(X) = M((X - M(X))^2) = M(X^2) - (M(X))^2$.

Deviația standard: $\sigma(X) = \sqrt{D(X)}$.

Momente de ordinul k:

- inițial $\nu_k = M(X^k)$,

- absolut $\underline{\nu}_k = M(|X|^k)$,

- central $\mu_k = M((X - M(X))^k)$.

Covarianța: $\text{cov}(X, Y) = M((X - M(X))(Y - M(Y))) = M(XY) - M(X)M(Y)$

Coeficientul de corelație : $\rho(X, Y) = \frac{\text{cov}(X, Y)}{\sqrt{D(X)}\sqrt{D(Y)}}$

Proprietăți:

1. $M(aX + b) = aM(X) + b$, $D(aX + b) = a^2 D(X)$ 2. $M(X + Y) = M(X) + M(Y)$

3. dacă X și Y sunt independente, atunci $M(XY) = M(X)M(Y)$ și $D(X + Y) = D(X) + D(Y)$

4. $h : \mathbb{R} \rightarrow \mathbb{R}$, X discr., atunci $M(h(X)) = \sum_{i \in I} h(x_i) p_i$, X cont., atunci $M(h(X)) = \int_{\mathbb{R}} h(x) f(x) dx$

5. $\text{cov}(X, Y) = M(XY) - M(X)M(Y)$ 6. $D\left(\sum_{i=1}^n a_i X_i\right) = \sum_{i=1}^n a_i^2 D(X_i) + 2 \sum_{1 \leq i < j \leq n} a_i a_j \text{cov}(X_i, X_j)$

7. X, Y independente $\Rightarrow \text{cov}(X, Y) = \rho(X, Y) = 0$ (X și Y sunt *necorelate*)

8. $-1 \leq \rho(X, Y) \leq 1$; $\rho(X, Y) = \pm 1 \Leftrightarrow \exists a, b \in \mathbb{R}, a \neq 0$ a. î. $Y = aX + b$

9. (X, Y) vect. al. de tip cont. cu pdf $f(x, y)$, $h : \mathbb{R}^2 \rightarrow \mathbb{R}^2$, atunci $M(h(X, Y)) = \int_{-\infty}^{\infty} \int_{-\infty}^{\infty} h(x, y) f(x, y) dx dy$.

Sem. 7, Inegalități; Șiruri de variabile aleatoare

Inegalitatea lui Hölder: $M(|XY|) \leq (M(|X|^p))^{\frac{1}{p}} \cdot (M(|Y|^q))^{\frac{1}{q}}$, $\forall p, q > 1$, $\frac{1}{p} + \frac{1}{q} = 1$.

Inegalitatea lui Markov: $P(|X| \geq a) \leq \frac{1}{a} M(|X|)$, $\forall a > 0$.

Inegalitatea lui Chebyshev: $P(|X - M(X)| \geq \epsilon) \leq \frac{D(X)}{\epsilon^2}$, $\forall \epsilon > 0$.

Convergență:

1) în probabilitate $X_n \xrightarrow{P} X$, dacă $\lim_{n \rightarrow \infty} P(|X_n - X| < \epsilon) = 1$, $\forall \epsilon > 0$;

2) tare $X_n \xrightarrow{t} X$, dacă $\lim_{n \rightarrow \infty} P\left(\bigcap_{k \geq n} \{|X_k - X| < \epsilon\}\right) = 1$, $\forall \epsilon > 0$;

3) aproape sigură $X_n \xrightarrow{a.s.} X$, dacă $P\left(\lim_{n \rightarrow \infty} X_n = X\right) = 1$;

4) în distribuție $X_n \xrightarrow{d} X$, dacă $\lim_{n \rightarrow \infty} F_n(x) = F(x)$, $\forall x \in \mathbb{R}$ punct de continuitate pentru F ;

5) în medie de ordin r , $0 < r < \infty$ $X_n \xrightarrow{L^r} X$, dacă $\lim_{n \rightarrow \infty} M(|X_n - X|^r) = 0$.

Proprietăți 1. 2) \Leftrightarrow 3) \Rightarrow 1) \Rightarrow 4) 2. 5) \Rightarrow 1).

STATISTICĂ

X o caracteristică de populație, X_1, X_2, \dots, X_n selecție de volum n , i.e. variabile independente și identic distribuite, cu același pdf ca X ; θ parametrul țintă, $\bar{\theta} = \bar{\theta}(X_1, X_2, \dots, X_n)$ estimator punctual.

Medie de selecție: $\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i$,

Moment de selecție: $\bar{\nu}_k = \frac{1}{n} \sum_{i=1}^n X_i^k$,

Moment absolut de selecție: $\bar{\mu}_k = \frac{1}{n} \sum_{i=1}^n (X_i - \bar{X})^k$,

Dispersie de selecție: $s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2$.

Funcție de verosimilitate a unei selecții: $L(X_1, \dots, X_n | \theta) = \prod_{i=1}^n f(X_i | \theta)$.

Informația lui Fisher: $I_n(\theta) = M \left[\left(\frac{\partial \ln L(X_1, \dots, X_n | \theta)}{\partial \theta} \right)^2 \right]$.

- dacă domeniul valorilor lui X nu depinde de θ , atunci $I_n(\theta) = -M \left[\frac{\partial^2 \ln L(X_1, \dots, X_n | \theta)}{\partial \theta^2} \right]$ și $I_n(\theta) = nI_1(\theta)$.

Eficiența unui estimator absolut corect: $e(\bar{\theta}) = \frac{1}{I_n(\theta) D(\bar{\theta})}$.

Estimatorul $\bar{\theta}$ este

- **nedeplasat:** $M(\bar{\theta}) = \theta$;
- **optimal:** $M(\bar{\theta}) = \theta$ și $D(\bar{\theta}) \leq D(\hat{\theta})$, $\forall \hat{\theta}$ estimator nedeplasat;
- **absolut corect:** $M(\bar{\theta}) = \theta$ și $\lim_{n \rightarrow \infty} D(\bar{\theta}) = 0$;
- **eficient:** absolut corect și $e(\bar{\theta}) = 1$.

Statistica $S = S(X_1, X_2, \dots, X_n)$ este

- **suficientă pentru θ :** pdf. cond. $f(X_1, \dots, X_n | S)$ nu depinde de $\theta \stackrel{\text{Crit.Fact.}}{<=>} L(x_1, \dots, x_n | \theta) = g(s, \theta) h(x_1, \dots, x_n)$;
- **completă pentru familia de distribuții $f(x | \theta)$, $\theta \in A$:** $M(\varphi(S)) = 0, \forall \theta \in A \Rightarrow \varphi \stackrel{\text{a.s.}}{=} 0$.

Metoda momentelor:

Se rezolvă sistemul $\nu_k = \bar{\nu}_k$ pentru toți parametrii necunoscuți.

Metoda verosimilității maxime:

Se rezolvă sistemul $\frac{\partial L(X_1, \dots, X_n | \theta)}{\partial \theta_j} = 0$ sau $\frac{\partial \ln L(X_1, \dots, X_n | \theta)}{\partial \theta_j} = 0$, $j = \overline{1, m}$ pentru parametrii necunoscuți $\theta = (\theta_1, \dots, \theta_m)$.

Teorema Lehmann-Scheffé: Fie $\hat{\theta}$ un estimator și S o statistică suficientă și completă pentru θ . Atunci $\bar{\theta} = M(\hat{\theta} | S)$ este un estimator optimal.

Inegalitatea Rao-Cramer: Fie $\bar{\theta}$ un estimator absolut corect pentru θ . Atunci $D(\bar{\theta}) \geq \frac{1}{I_n(\theta)}$.

Testarea ipotezelor statistice: $H_0 : \theta = \theta_0$, cu una din alternativele $H_1 : \begin{cases} \theta < \theta_0 & (\text{test la stânga}), \\ \theta > \theta_0 & (\text{test la dreapta}), \\ \theta \neq \theta_0 & (\text{test bilateral}). \end{cases}$

Nivel de semnificație: $\alpha = P(\text{eroare de tipul I}) = P(\text{se respinge } H_0 | H_0) = P(TS \in RR | \theta = \theta_0)$.

Eroare de tipul II: $\beta = P(\text{eroare de tipul II}) = P(\text{se acceptă } H_0 | H_1) = P(TS \notin RR | H_1)$.

Puterea unui test: $\pi(\theta^*) = P(\text{se respinge } H_0 | \theta = \theta^*) = P(TS \in RR | \theta = \theta^*)$.

Lema Neyman-Pearson(LNP): Se testează ipotezele simple $H_0 : \theta = \theta_0$, $H_1 : \theta = \theta_1$. Fie $L(\theta^*)$ funcție de verosimilitate a selecției, atunci când $\theta = \theta^*$. Atunci pentru orice $\alpha \in (0, 1)$, un cel mai puternic test (un test care maximizează puterea $\pi(\theta_1)$) este testul cu $RC = \left\{ \frac{L(\theta_1)}{L(\theta_0)} \geq k_\alpha \right\}$, unde $k_\alpha > 0$ este o constantă.